

## Лабораторная работа № 9

### Методы разделения источников сигналов: PCA, GED, ICA

**1.1 Постановка задачи.** Задача разделения источников сигналов заключается в восстановлении независимых сигналов-источников из их линейной смеси, наблюдаемой через многоканальную систему измерений.

*Математическая модель смешивания:*

$$\mathbf{X} = \mathbf{A}\mathbf{S} + \mathbf{N}$$

где:

- $\mathbf{X} \in \mathbb{R}^{M \times T}$  — матрица наблюдаемых данных ( $M$  каналов,  $T$  временных отсчётов)
- $\mathbf{A} \in \mathbb{R}^{M \times K}$  — матрица смешивания (пространственные паттерны источников)
- $\mathbf{S} \in \mathbb{R}^{K \times T}$  — матрица исходных источников ( $K$  источников)
- $\mathbf{N} \in \mathbb{R}^{M \times T}$  — матрица шума

**Цель:** найти матрицу разделения  $\mathbf{W}$  такую, что  $\hat{\mathbf{S}} = \mathbf{W}\mathbf{X}$  максимально близко к истинным источникам  $\mathbf{S}$ .

## 1.2. Метод главных компонент (PCA — Principal Component Analysis)

**Основная идея.** PCA находит ортогональные направления в пространстве данных, которые максимизируют дисперсию. Первые главные компоненты захватывают наибольшую долю вариативности данных. Алгоритм вычисления:

1. Центрирование данных:

$$\mathbf{X}_c = \mathbf{X} - \bar{\mathbf{X}}, \quad \bar{\mathbf{X}} = \frac{1}{T} \sum_{t=1}^T \mathbf{x}_t$$

2. Вычисление ковариационной матрицы:

$$\mathbf{C} = \frac{1}{T-1} \mathbf{X}_c \mathbf{X}_c^T \in \mathbb{R}^{M \times M}$$

3. Собственное разложение:

$$\mathbf{C} \mathbf{v}_i = \lambda_i \mathbf{v}_i, \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_M$$

4. Проекция на главные компоненты:

$$\mathbf{S}_{PCA} = \mathbf{V}^T \mathbf{X}_c$$

где  $\mathbf{V} = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_K]$  — матрица собственных векторов.

### Свойства PCA

- Компоненты ортогональны:  $\mathbf{v}_i^T \mathbf{v}_j = \delta_{ij}$
- Доля объяснённой дисперсии  $i$ -й компонентой:  $p_i = \frac{\lambda_i}{\sum_j \lambda_j}$
- **Ограничение:** PCA максимизирует дисперсию, но не гарантирует статистическую независимость компонент

## 1.3.Обобщённое собственное разложение (GED,Generalized Eigenvalue Decomposition)

**Основная идея.** GED находит направления, которые максимизируют отношение дисперсии в одном условии к дисперсии в другом условии (например, сигнал/шум).

**Обобщённая задача на собственные значения:**

$$\mathbf{C}_{signal}\mathbf{w} = \lambda\mathbf{C}_{noise}\mathbf{w}$$

где:

- $\mathbf{C}_{signal}$  — ковариационная матрица данных с сигналом
- $\mathbf{C}_{noise}$  — ковариационная матрица шума (референсное условие)

### Преимущества GED

- Явное использование информации о шуме
- Эффективно при коррелированном шуме между каналами
- Позволяет выделять компоненты, специфичные для определённого условия

### Алгоритм GED:

1. Вычисление ковариационных матриц для двух условий:

$$\mathbf{C}_1 = \text{cov}(\mathbf{X}_1), \quad \mathbf{C}_2 = \text{cov}(\mathbf{X}_2)$$

2. Решение обобщённой задачи (с регуляризацией при необходимости):

$$\mathbf{C}_1\mathbf{w} = \lambda(\mathbf{C}_2 + \epsilon\mathbf{I})\mathbf{w}$$

3. Сортировка собственных векторов по убыванию  $\lambda$  (максимальное отношение сигнал/шум)

4. Вычисление **форвард-модели** (пространственного паттерна):

$$\mathbf{a} = \frac{\mathbf{C}_{signal}\mathbf{w}}{\mathbf{w}^T\mathbf{C}_{noise}\mathbf{w}}$$

## 1.4. Анализ независимых компонент (ICA — Independent Component Analysis)

**Основная идея.** ICA находит компоненты, которые являются **статистически независимыми**, а не просто некоррелированными (как в PCA).

**Модель ICA:**  $\mathbf{X} = \mathbf{AS}$ ,  $\mathbf{S} = \mathbf{WX}$ ,  $\mathbf{W} = \mathbf{A}^{-1}$

Критерий независимости: минимизация взаимной информации или максимизация негауссовости компонент.

**Алгоритм FastICA**

1. Предварительная обработка данных:  $\mathbf{Z} = \mathbf{VD}^{-1/2}\mathbf{V}^T\mathbf{X}_c$

2. Итеративное обновление вектора  $\mathbf{w}$ :

$$\mathbf{w}^+ = \mathbb{E}\{\mathbf{Z}g(\mathbf{w}^T\mathbf{Z})\} - \mathbb{E}\{g'(\mathbf{w}^T\mathbf{Z})\}\mathbf{w}$$

$$\mathbf{w} = \frac{\mathbf{w}^+}{\|\mathbf{w}^+\|}$$

где  $g(u) = \tanh(u)$  или  $g(u) = u^3$  — нелинейная функция.

3. Ортогонализация при извлечении нескольких компонент

### Свойства ICA

- Компоненты статистически независимы (более сильное условие, чем некоррелированность)
- Порядок компонент произвольный (нет естественной сортировки по важности)
- Амплитуда и знак компонент неопределённые (требуют нормализации для интерпретации)

## 1.5. Сравнительная характеристика методов

| Критерий                 | PCA                | GED                             | ICA                          |
|--------------------------|--------------------|---------------------------------|------------------------------|
| Критерий оптимизации     | Максимум дисперсии | Максимум отношения сигнал/шум   | Статистическая независимость |
| Ортогональность          | Да                 | Нет (в общем случае)            | Нет                          |
| Требуется референс       | Нет                | Да (ковариация шума)            | Нет                          |
| Устойчивость к шуму      | Низкая             | Высокая                         | Средняя                      |
| Интерпретируемость       | Средняя            | Высокая (при известном условии) | Высокая                      |
| Вычислительная сложность | $O(M^3)$           | $O(M^3)$                        | $O(M^2T \cdot iter)$         |



## 2. ЗАДАЧИ ЛАБОРАТОРНОЙ РАБОТЫ

### Задача 1. PCA: разделение двух пространственно-временных источников

**Цель:** Реализовать PCA для выделения двух гармонических источников из зашумлённой многоканальной смеси.

**Модель данных (генерируется программно):**

- 10 каналов, 500 временных отсчётов.
- Источник 1: амплитуда 2.0, частота 0.05 (нормированная), пространственный паттерн  $\sin(2\pi k/10)$ .
- Источник 2: амплитуда 1.0, частота 0.10, пространственный паттерн  $\cos(2\pi k/10)$ .
- Аддитивный гауссовский шум с уровнем  $\text{NOISE\_LEVEL} = 0.3$ .

**Задачи:**

1. Сгенерировать данные с помощью функции `generate_data()` (см. шаблон).
2. Выполнить центрирование данных (вычитание среднего по каналам).
3. Вычислить ковариационную матрицу центрированных данных и найти её собственные значения и векторы.
4. Отсортировать компоненты по убыванию собственных значений.
5. Получить главные компоненты как проекцию: `principal_components = eigenvectors.T @ data_centered`.

**6. Построить графики:**

1. **Рис. 1:** Исходные зашумлённые данные (каналы с вертикальным сдвигом) и матрица корреляций между каналами.
2. **Рис. 2:** Нормированные собственные значения (доля объяснённой дисперсии) и пространственные веса первых трёх компонент.
3. **Рис. 3:** Временные ряды первых трёх компонент, наложенные на истинные источники (после нормализации амплитуды и знака).


**7. Рассчитать метрики качества:**

1. Корреляцию PC1 с источником 1, PC2 с источником 2.
2. Стандартное отклонение PC3 (шумовой компоненты).
3. Долю объяснённой дисперсии для первых пяти компонент.


**Ожидаемый результат:**

Корреляция PC1 с источником 1  $> 0.99$ , PC2 с источником 2  $> 0.99$ , PC3 имеет малую амплитуду и низкую корреляцию с любым из источников.


Исходные зашумлённые данные




Матрица корреляций каналов




Объяснённая дисперсия (собственные значения)



Пространственные веса компонент



Временные компоненты PCA



## Задача 2. GED: разделение источников с использованием информации о шуме

**Цель:** Реализовать GED для выделения источников при высоком уровне шума, используя отдельную оценку ковариации шума.

### Модель:

- Те же два источника, что в задаче 1, но уровень шума повышен до  $\text{NOISE\_LEVEL} = 0.5$ , чтобы подчеркнуть преимущество GED.
- Известны ковариации:  $C_{\text{signal}}$  (смесь сигнала с шумом) и  $C_{\text{noise}}$  (только шум).



### Задачи:

1. Сгенерировать зашумлённые данные (как в задаче 1, но с  $\text{NOISE\_LEVEL} = 0.5$ ). Сохранить чистый шум для вычисления  $C_{\text{noise}}$ .
2. Вычислить ковариационную матрицу сигнала  $\text{cov\_signal}$  по зашумлённым данным и ковариацию шума  $\text{cov\_noise}$  по шуму.
3. Решить обобщённую задачу на собственные значения:  $\text{scipy.linalg.eigh}(\text{cov\_signal}, \text{cov\_noise} + \text{reg} * \text{I})$ .
4. Отсортировать собственные значения и векторы по убыванию  $\lambda\lambda$ .
5. Вычислить форвард-модели (пространственные паттерны) для первых трёх компонент:  
$$\mathbf{a} = (C_{\text{signal}} \mathbf{w}) / (\mathbf{w}^T C_{\text{noise}} \mathbf{w})$$
6. Построить графики:
  1. **Рис. 4:** Исходные зашумлённые данные (аналогично задаче 1).
  2. **Рис. 5:** Спектр обобщённых собственных значений (нормированных на максимальное) и пространственные паттерны GED1, GED2, GED3.
  3. **Рис. 6:** Временные ряды компонент (после проекции) с наложением истинных источников.
7. Рассчитать корреляции GED1 с источником 1 и GED2 с источником 2, а также кросс-корреляции.
8. Сравнить с результатами PCA (таблица).




### Ожидаемый результат:

Корреляции GED1 и GED2 с истинными источниками остаются выше 0.99, тогда как PCA при уровне шума 0.5 даёт корреляции  $\approx 0.85$ – $0.90$ .





Отношение сигнал/шум (собственные значения GED) Пространственные паттерны, извлечённые GED



### **Задача 3. ICA: разделение на основе статистической независимости**

**Цель:** Применить FastICA для выделения независимых источников без использования информации о шуме.


#### **Задачи:**

1. Сгенерировать зашумлённые данные (как в задаче 2,  $\text{NOISE\_LEVEL} = 0.5$ ).
2. Применить FastICA из `sklearn.decomposition`:
  - Отбеливание (`whiten='arbitrary-variance'`).
  - Извлечь столько же компонент, сколько каналов.
3. Получить матрицу смешивания `mixing_` и компоненты (источники).
4. Отсортировать компоненты по убыванию энергии пространственных карт (сумма квадратов весов).
5. Нормализовать временные ряды и пространственные карты для сравнения с истинными источниками (выравнивание амплитуды и знака).
6. Построить графики:
  - Исходные зашумлённые данные.
  - Энергия компонент (нормированная) и пространственные карты ICA1, ICA2, ICA3.
  - Временные ряды ICA1, ICA2, ICA3 с наложением истинных источников.
7. Рассчитать корреляции:
  - ICA1 с источником 1, ICA2 с источником 2.
  - Стандартное отклонение шумовой компоненты.
8. **Объяснить**, почему порядок компонент в ICA произвольный (в отличие от PCA) и как это влияет на интерпретацию. Сравнить результаты ICA с PCA и GED.


#### **Ожидаемый результат:**

При уровне шума 0.5 ICA обычно даёт корреляции 0.88–0.92, что выше, чем у PCA, но ниже, чем у GED (поскольку GED использует дополнительную информацию о шуме).


Исходные зашумлённые данные




Матрица корреляций каналов




Энергия пространственных карт ICA



Пространственные паттерны, извлечённые ICA



Временные компоненты ICA



## Задача 4\*. Применение GED к моделированию ЭЭГ-сигналов

**Цель:** Применить GED для выделения активности дипольных источников в моделированной ЭЭГ с реальной топологией каналов.

### Модель:

- Источники: два диполя (номера 108 и 134) с частотами  $f_1=15$  Гц и  $f_2=10$  Гц.
- Проекция на скальп:  $X=GJ+NX=GJ+N$ , где  $G$  — матрица усиления (leadfield) из файла emptyEEG.mat.
- 200 эпох (триалов) по 1000 отсчётов, частота дискретизации 500 Гц.
- Пре-стимульный интервал (500 отсчётов) — только шум, пост-стимульный (500 отсчётов) — сигнал + шум.

### Задачи:

1. Загрузить файл emptyEEG.mat.
2. Сгенерировать активность диполей с гармоническими сигналами, случайной фазой в каждой эпохе и наложить фоновый шум.
3. Спроецировать активность на скальп: `data = Gain @ dipole_activity.T`.
4. Решить обобщённую задачу GED.
5. Спроецировать данные на полученные фильтры, усреднить по эпохам и сравнить временные ряды компонент с истинными усреднёнными диполями.
6. Выполнить спектральный анализ (БПФ) для каждой компоненты, отметить частоты 10 и 15 Гц.


### Ожидаемый результат:

GED1 коррелирует с диполем 1 (15 Гц) с коэффициентом  $>0.95$ , GED2 — с диполем 2 (10 Гц)  $>0.95$ . Топографии извлечённых компонент визуально соответствуют истинным топографиям диполей. Спектры мощности компонент показывают ярко выраженные пики на соответствующих частотах.




## Исходные пространственные паттерны диполей

Истинный диполь 1 (15 Гц)




Истинный диполь 2 (10 Гц)




## Пространственные паттерны: истинные источники и извлечённые GED


Истинный диполь 1



Истинный диполь 2



GED компонента 1



GED компонента 2

